


Flip Distribution Alignment VAE for Multi-Phase MRI Synthesis

MICCAI 2025
citations 2


Department of Computer Engineering and Artificial Intelligence
MAI Lab.

YS Park




- Introduction
- Method
- Experiments
- Conclusion


- Multi-phase contrast-enhanced (CE) MRI는 병변, 종양, 혈관 이상을 진단하는 데 중요한 정보를 제공합니다. 하지만 촬영 시간이 길고, 가돌리늄 조영제 사용으로 신장 독성 위험이 있기 때문에 모든 시기 영상을 직접 촬영하기는 부담스러움.
- 따라서 이미 촬영한 비조영 또는 특정 시기의 MRI로부터 다른 시기의 영상을 합성하면 촬영 시간과 조영제 사용을 줄일 수 있음.
- 기존에는 크게 **Diffusion model (DM)** 기반 방법과 **Auto Encoder (AE)** 기반 방법으로 나뉨.
 - DM: high quality but high computation, inflexible training strategies.
 - AE: greater flexibility in training by allowing direct **manipulation of latent space** structures and optimization objectives.



Phase	주로 보는 특징
Pre	조영제 투여 전 병변의 기본 구조
Arterial (CA)	간동맥 혈류와 동맥성 조영증강
Venous/portal venous (CV)	문맥 및 간 실질 조영, 병변 검출
Delayed	늦은 조영제 추적과 washout, 섬유성 성분

- **many-to-one:** 여러 시기의 MRI가 모두 준비된 paired data를 필요함.
- **one-to-one:** 입력과 목표 영상 사이의 공통 특징이나 직접적인 변환에 집중하지만, 각 영상 시기에만 존재하는 독립적인 특징은 충분히 고려하지 못함.
- Limited paired medical dataset을 사용하는데도 매우 깊고 큰 AE를 사용함.
 - 데이터 규모에 비해 모델이 지나치게 클 수 있음.
- Paired data를 쓰되, model parameters를 줄이고 efficiency를 늘려보자.





$$\mu_A, \sigma_A = \text{Encoder}(x_A), \quad \mu_B, \sigma_B = \text{Encoder}(x_B)$$


$$L_{KL} = D_{KL}(N(\mu, \sigma^2) || N(0, I))$$

$$\begin{aligned} z_{A \rightarrow A} &\sim N(\mu_A, \sigma_A^2), & \hat{x}_{A \rightarrow A} &= \text{Decoder}_A(z_{A \rightarrow A}) \\ z_{B \rightarrow B} &\sim N(\mu_B, \sigma_B^2), & \hat{x}_{B \rightarrow B} &= \text{Decoder}_B(z_{B \rightarrow B}) \end{aligned}$$

$$L_{FDA} = |\mu_A + \mu_B|_1 + |\sigma_A^2 - \sigma_B^2|_1$$

$$\begin{aligned} z_{A \rightarrow B} &\sim N(-\mu_A, \sigma_A^2), & \hat{x}_{A \rightarrow B} &= \text{Decoder}_B(z_{A \rightarrow B}) \\ z_{B \rightarrow A} &\sim N(-\mu_B, \sigma_B^2), & \hat{x}_{B \rightarrow A} &= \text{Decoder}_A(z_{B \rightarrow A}) \end{aligned}$$


$$\begin{aligned} L_{FDA-VAE} &= \lambda_{rec} L_{Rec} + L_{Trans} + \lambda_{GAN} L_{GAN} + \lambda_{perce} L_{Perce} \\ &+ \lambda_{kl} L_{KL} + \lambda_{fda} L_{FDA} \end{aligned}$$





구분	내용
Dataset	LLD-MMRI 2023
# patients	498명
Tumor	총 7종: 양성 4종, 악성 3종
MRI Phase	Precontrast (Pre), Arterial (CA), Venous (CV), Delayed (Delay)
Task	Early-to-late phase synthesis 6개: Pre→CA, Pre→CV, Pre→Delay, CA→CV, CA→Delay, CV→Delay
Registration	ANTsPy non-rigid registration
Reference Phase	C+V phase
Data split	질병 유형별 그룹화 후 Training : Validation = 4 : 1
Intensity preprocessing	상위 0.1% intensity clipping
Normalization	Intensity normalization
Image size	256 × 256

구분	내용
Metrics	PSNR: 픽셀별 오차를 측정. SSIM: 밝기, 대비, 구조의 유사도를 측정. LPIPS: feature space에서 시각적 유사도를 측정.
Optimizer	Adam
Initial Learning Rate	1×10^{-4}
Epoch	40 epochs
HW	NVIDIA RTX 4090 24 GB × 4
Training time	약 6.5시간

Method/Task	Pre→CA	Pre→CV	Pre→Delay	CA→CV	CA→Delay	CV→Delay
PSNR(dB)↑						
Pix2Pix [12]	24.79	23.74	23.60	24.73	24.56	27.27
ResVit [9]	<u>25.34</u>	24.06	24.33	25.88	25.41	26.63
TransUnet [6]	25.01	<u>24.74</u>	<u>24.74</u>	<u>26.18</u>	<u>25.86</u>	26.35
PTNet [31]	24.85	23.68	24.03	25.38	24.68	<u>27.89</u>
I2I-Mamba [2]	24.95	24.39	24.12	25.46	25.24	25.61
VAE(backbone)	25.23	<u>24.96</u>	23.63	26.48	24.65	27.08
VAE (KL+FDA)	<u>25.71</u>	24.95	25.07	<u>26.54</u>	<u>26.10</u>	<u>27.99</u>
FDA-VAE(Ours)	25.89	24.98	<u>24.89</u>	26.72	26.33	28.59
SSIM(%)↑						
Pix2Pix [12]	80.41	68.23	77.14	78.50	78.95	84.56
ResVit [9]	<u>81.79</u>	76.32	<u>78.99</u>	79.20	81.90	84.98
TransUnet [6]	81.22	<u>79.79</u>	78.84	<u>82.38</u>	<u>83.07</u>	84.64
PTNet [31]	81.35	77.56	78.69	81.75	80.08	<u>86.19</u>
I2I-Mamba [2]	81.16	76.91	78.51	79.44	81.47	82.85
VAE(backbone)	72.72	79.60	76.29	82.57	74.23	80.42
VAE (KL+FDA)	<u>82.99</u>	<u>80.10</u>	81.32	<u>83.07</u>	82.99	<u>86.41</u>
FDA-VAE(Ours)	83.70	80.68	<u>81.17</u>	84.01	83.84	87.48
LPIPS↓						
Pix2Pix [12]	0.0854	0.0903	0.0914	0.0837	0.0851	0.0568
ResVit [9]	0.0713	0.0776	<u>0.0774</u>	<u>0.0626</u>	<u>0.0682</u>	0.0534
TransUnet [6]	0.0768	0.0761	0.0791	0.0637	0.0677	0.0632
PTNet [31]	0.0771	0.0787	0.0824	0.0635	0.0764	0.0463
I2I-Mamba [2]	0.0739	<u>0.0750</u>	0.0783	0.0646	0.0698	0.0632
VAE(backbone)	0.0799	0.0779	0.1064	0.0661	0.0818	0.0576
VAE (KL+FDA)	<u>0.0720</u>	<u>0.0735</u>	0.0716	0.0656	<u>0.0667</u>	0.0490
FDA-VAE(Ours)	0.0713	0.0729	<u>0.0723</u>	0.0611	0.0620	<u>0.0465</u>



	Pix2Pix	ResVit	TransUnet	PTNet	I2I-Mamba	Ours
Params (m)	51.89	117.72	100.45	<u>26.83</u>	100.64	11.78
Inference (secs/slice)	0.0019	0.0121	0.0109	0.0141	0.0071	<u>0.0050</u>



- FDA-VAE는 다중 phase MRI 합성을 위한 경량 VAE 프레임워크임.
- FDA constraint와 Y-shaped 양방향 학습을 사용하여 입력·타겟 이미지의 공통 특징과 독립 특징을 latent 공간에서 보존하는데 성공함.
- 기존 방법보다 합성 품질은 향상함과 동시에 모델 파라미터 수와 추론 시간은 감소함.
- 향후에는 unpaired 데이터으로 확장할 계획임.