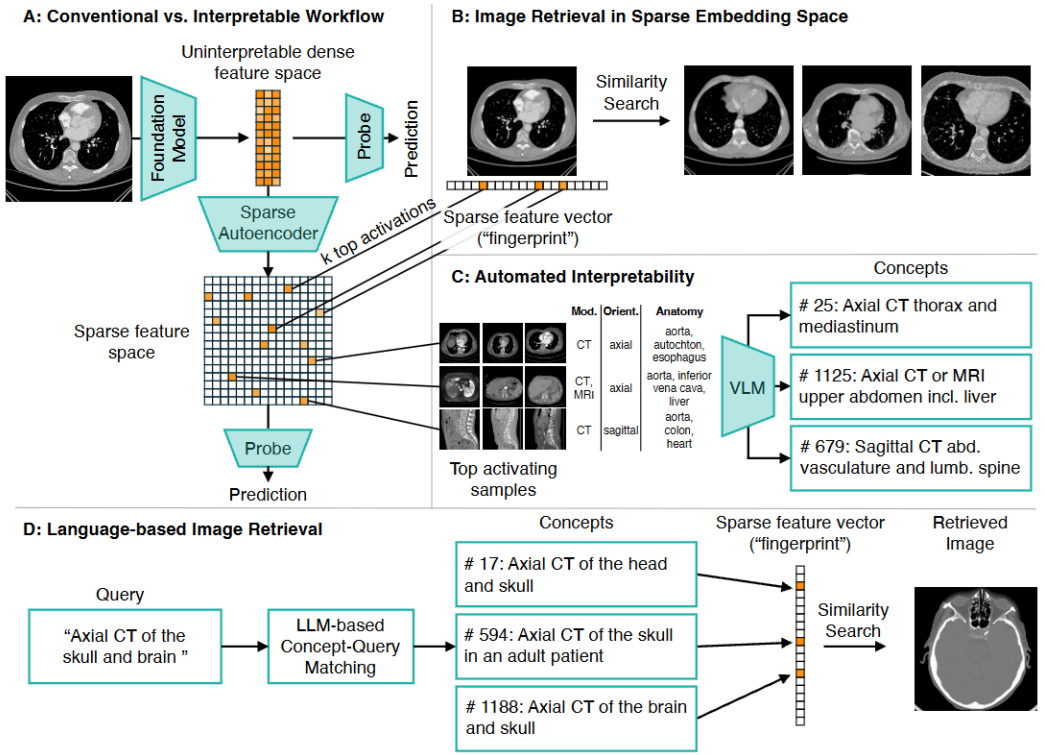
Sparse Autoencoders for Interpretable Medical Image Representation Learning

MICCAI 2026



Department of Computer Engineering and Artificial Intelligence
MAI Lab.

YS Park

국립부경대학교 PUKYONG NATIONAL UNIVERSITY

Medical AI laboratory

Index

- Introduction
- Method
- Experiments & Results
- Conclusion

Introduction

- Fondation Model (FM) 은 다양한 Task에서 강한 performance를 보이나 정보를 abstract, low-dimensional feature representation으로 인코딩함.

- 임상 배포 환경에서 interpertability는 필수로 요구되는데 해당 특성으로 인해 임상적인 표현과 misalignment가 발생함.

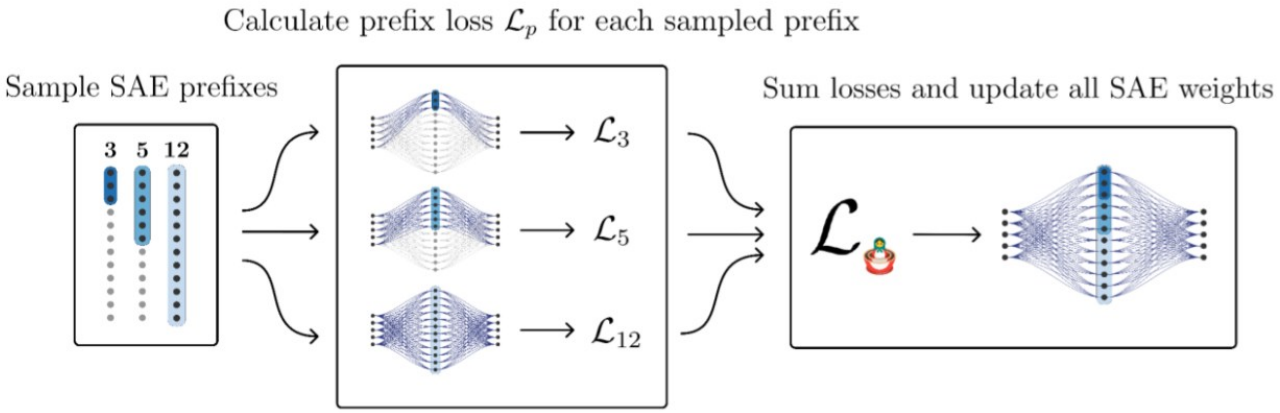
- 이를 해결하기 위해 Sparse Autoencoder를 비롯한 **Mechanistic interpretability**라는 분야가 연구되고 있으며, 이는 사람이 이해할 수 있는 요소로 모델의 내부 표현을 reverse enginering 하는 것을 목표로 함.

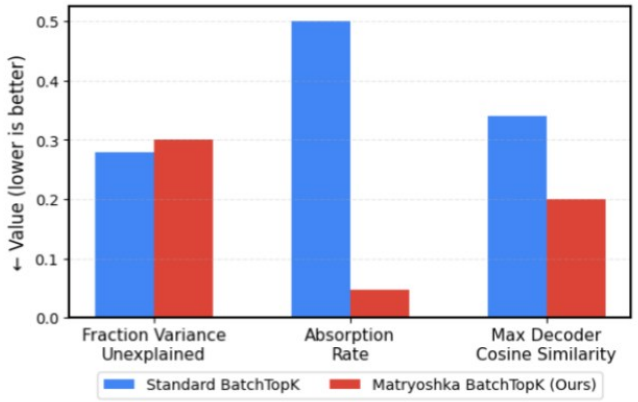
- RQ 1. SSL vision model이 명시적인 해부학 라벨을 받지 않고도 해부학적·임상적 개념을 학습하는가?
- RQ 2. 그리고 SAE가 서로 다른 구조를 가진 파운데이션 모델에서 그 개념을 일관되게 드러낼 수 있는가?

Methods

- **Sparse Autoencoder**
  - Matryoshka SAE with $L = 4$ nested dictionary levels of increasing size $[D_1, D_2, D_3, D_4]$.
  - Loss: MSE
  - BatchTopK: 배치 내에서 샘플당 평균적으로 k 개의 feature가 활성화됨.
    - allowing flexible per-sample allocation unlike fixed per-sample TopK

- **Monosemanticity scoring.**
  - $M(f) = C(f) \times S(f) = coherence \times specificity$
  - $C(f) = \frac{2}{n(n-1)} \sum_{i<j} J(O_i, O_j), n = 10$
  - $S(f) = 1 - \frac{H(p)}{\log K}, H(p) = -\sum_{k=1}^{K} p_k \log p_k, K = 121$

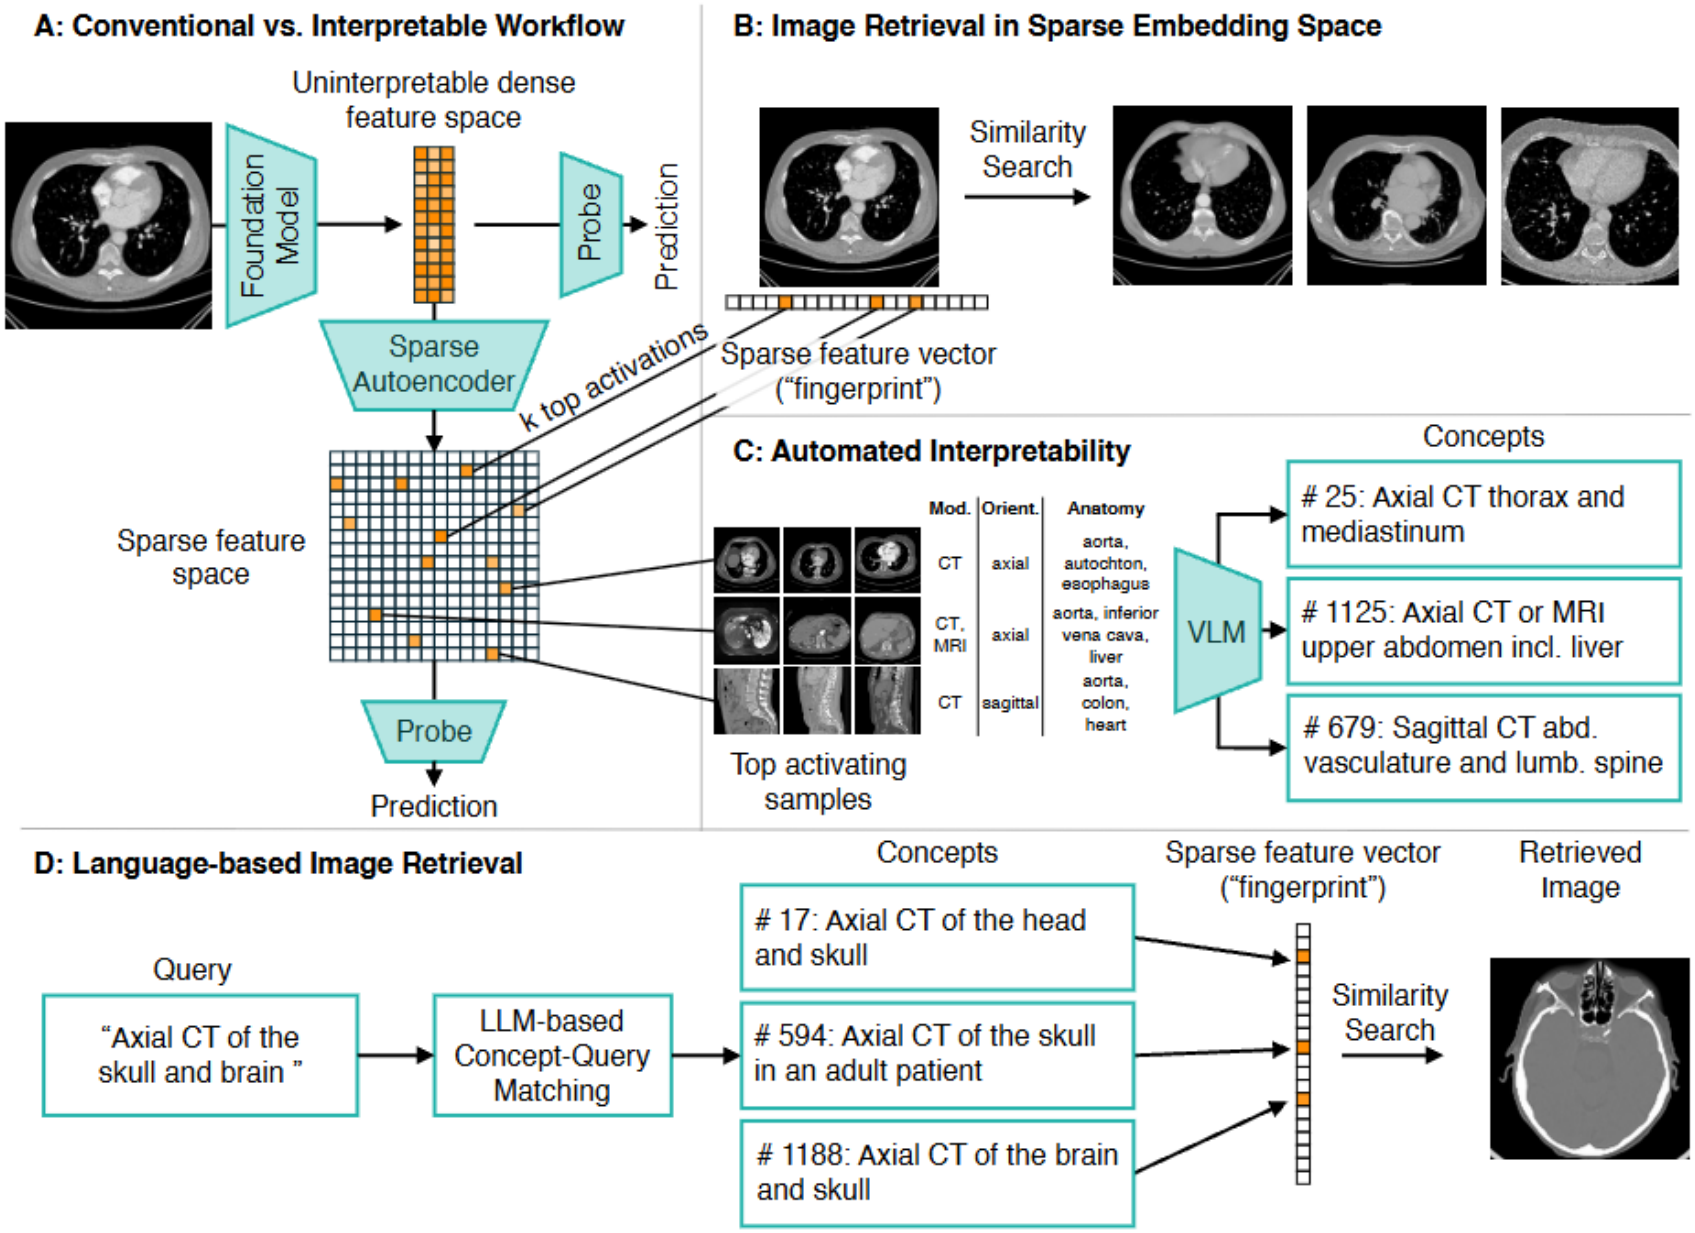




Methods

- **Sparse Fingerprint Retrieval.**
  - 영상마다 가장 크게 활성화된 특징 k개와 활성값을 **Fingerprint**로 만들고, **Fingerprint similarity**로 비슷한 영상을 검색함.
- **Automated Feature Interpretation.**
  - 특징별로 상위 활성 영상 20장 중 서로 가장 다른 영상 5장 + 메타데이터 (촬영기법, 방향, 장기, 환자정보)를 바탕으로 MedGemma-27B를 이용하여 설명을 생성함.
  - 독립된 MedGemma-27B(판정관)가 영상 5장과 5개의 설명 보기(정답 설명 1개 + 10회 이상 활성화된 다른 유의미한 특징에서 무작위로 뽑은 오답 4개)를 주어 판정관은 1등부터 5등까지 순위를 매김.
    - 정답 설명이 1등(Rank 1)을 차지할수록 그 특징이 뚜렷하고 명확한 개념을 담고 있다는 뜻임.
- **Language-Driven Image Retrieval.**
  - 임상 문장에서 관련 특징 설명을 고르고, 그 특징들로 검색 지문을 만들어 영상을 찾음.

Methods

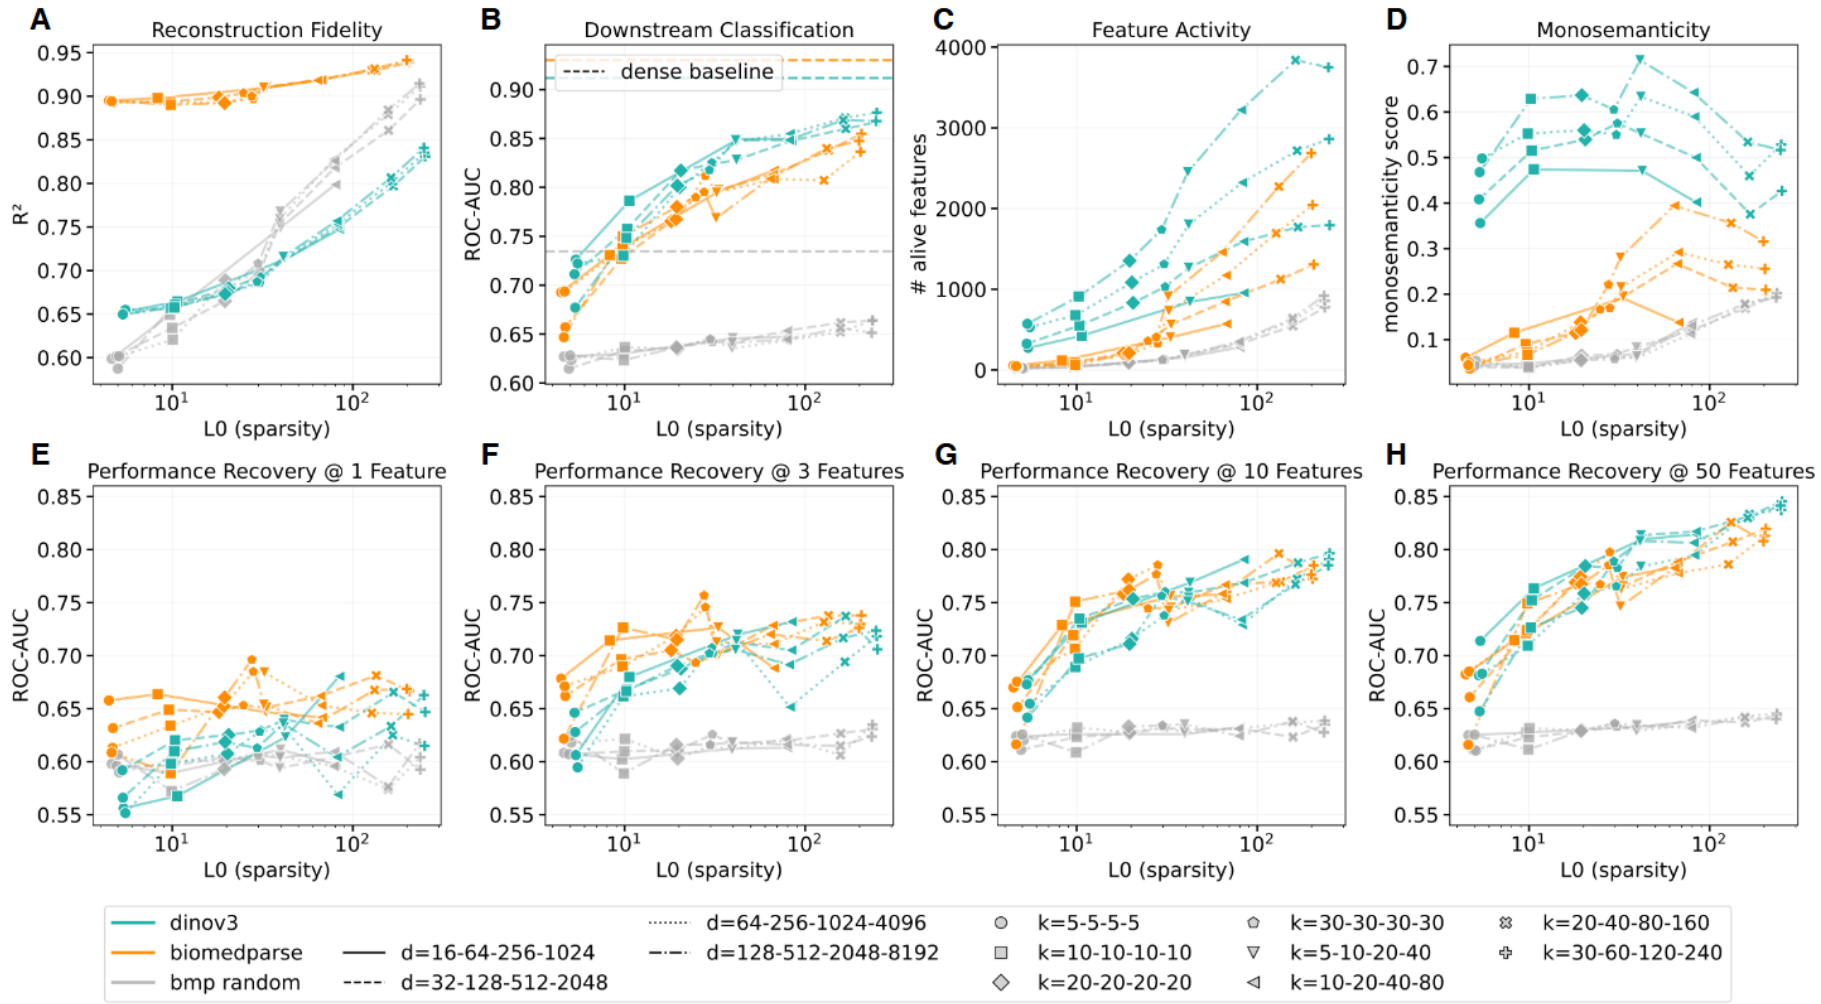

A: Conventional vs. Interpretable Workflow
Uninterpretable dense feature space
Foundation Model
Probe
Prediction
Sparse Autoencoder
k top activations
Sparse feature space
Probe
Prediction
B: Image Retrieval in Sparse Embedding Space
Similarity Search
Sparse feature vector ("fingerprint")
C: Automated Interpretability
Concepts
Mod.
Orient.
Anatomy
CT
axial
aorta, autochton, esophagus
CT, MRI
axial
aorta, inferior vena cava, liver
CT
sagittal
aorta, colon, heart
VLM
25: Axial CT thorax and mediastinum
1125: Axial CT or MRI upper abdomen incl. liver
679: Sagittal CT abd. vasculature and lumb. spine
Top activating samples
D: Language-based Image Retrieval
Query
"Axial CT of the skull and brain "
LLM-based Concept-Query Matching
Concepts
17: Axial CT of the head and skull
594: Axial CT of the skull in an adult patient
1188: Axial CT of the brain and skull
Sparse feature vector ("fingerprint")
Similarity Search
Retrieved Image

Experiments & Results

구분	설정	내용
데이터셋	출처	TotalSegmentator 데이터셋
	스캔 수	총 1,844건: CT 1,228건, MRI 616건
	이미지 수	2D 이미지 909,873장
	메타데이터	이미지당 138개 필드: 해부학적 구조, 촬영 조건, 인구통계 정보 등
데이터 분할	시험 세트	3개 기관의 스캔 전체를 학습에서 제외. 전체 이미지의 14.1%
	학습·검증 세트	나머지 스캔을 modality, 연령대, 성별 기준으로 층화해 80:20 분할
	전체 기준 비율	학습 68.6%, 검증 17.3%, 시험 14.1%
SAE 학습	입력 표현	BiomedParse와 DINOv3의 이미지 임베딩
	최적화 방법	Adam
	학습률	10^{-4} 에서 10^{-6} 까지 cosine annealing
	학습 기간·배치	100 epochs, batch size 2,048
설정 탐색	FM별 설정 수	각 FM마다 96개 설정
	사전 크기	4개 크기 조합군. $[16,64,256,1024]$~$[128,512,2048,8192]$
	희소성 패턴	8가지: 고정 Top-K 4종, 단계별로 K를 늘리는 progressive K 4종
비교 기준	Dense embedding	원래 dense embedding의 성능을 상한선으로 사용
	Random-weight BiomedParse	학습된 시각 표현의 효과와 모델 구조 자체의 효과를 분리하기 위한 기준선

Experiments & Results

- SAE Quality
  - Latent space reconstruction (R^2) & Downstream performance (ROC-AUC)



Experiments & Results

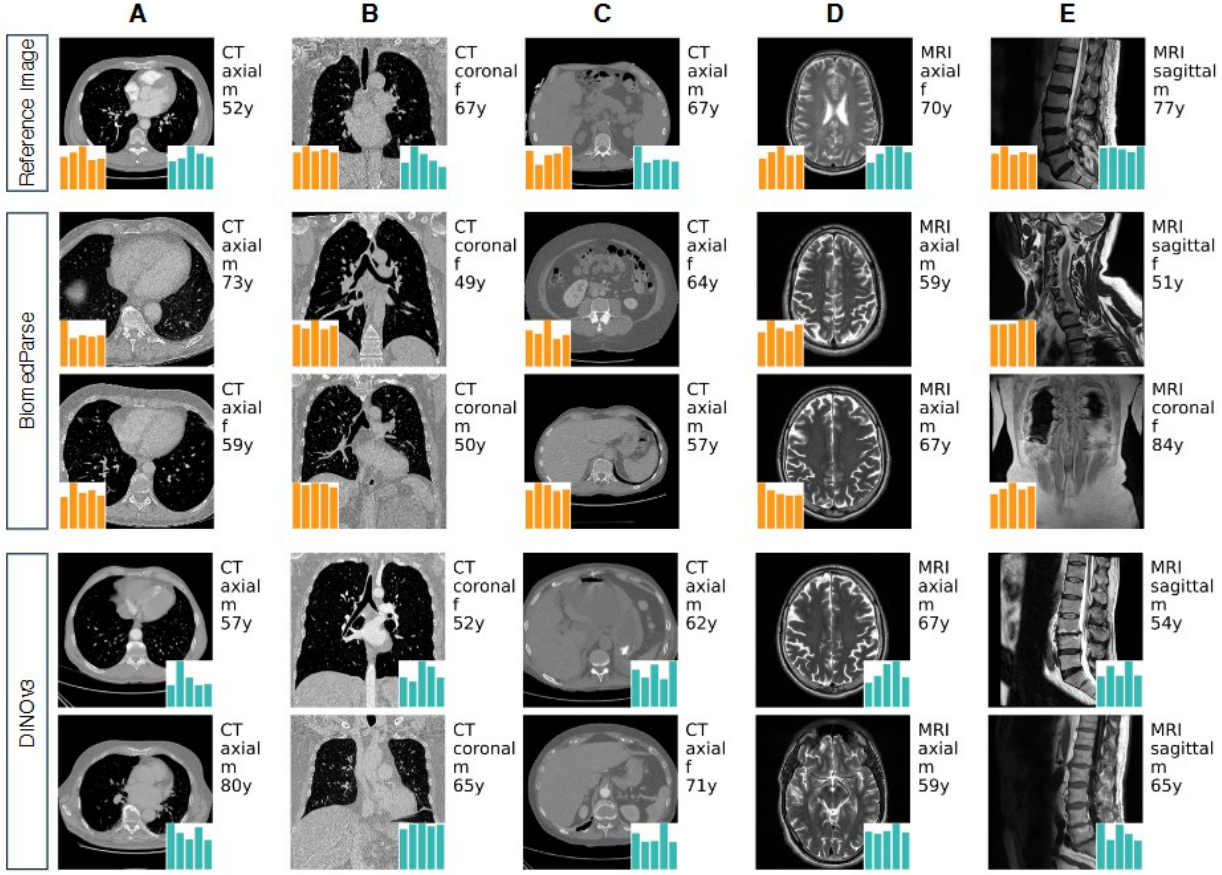
- **SAE Configuration Ranking.**

Table 1. Top-3 SAE configurations per FM ranked by combined monosemanticity and performance recovery score (32 configurations each). Bold: selected optimal configuration. #Mono/Perf/Comb: monosemanticity/performance/combined rank.

Model	Dict Sizes	Top-K Values	#Mono	#Perf	#Comb
BiomedParse	**128, 512, 2048, 8192**	**20, 40, 80, 160**	2	**3**	1
	128, 512, 2048, 8192	30, 60, 120, 240	3	6	2
	128, 512, 2048, 8192	10, 20, 40, 80	1	12	3
DINOv3	**128, 512, 2048, 8192**	**5, 10, 20, 40**	1	**11**	1
	64, 256, 1024, 4096	5, 10, 20, 40	4	10	2
	128, 512, 2048, 8192	10, 20, 40, 80	2	14	3

Experiments & Results

- **Sparse Feature Interpretability.**



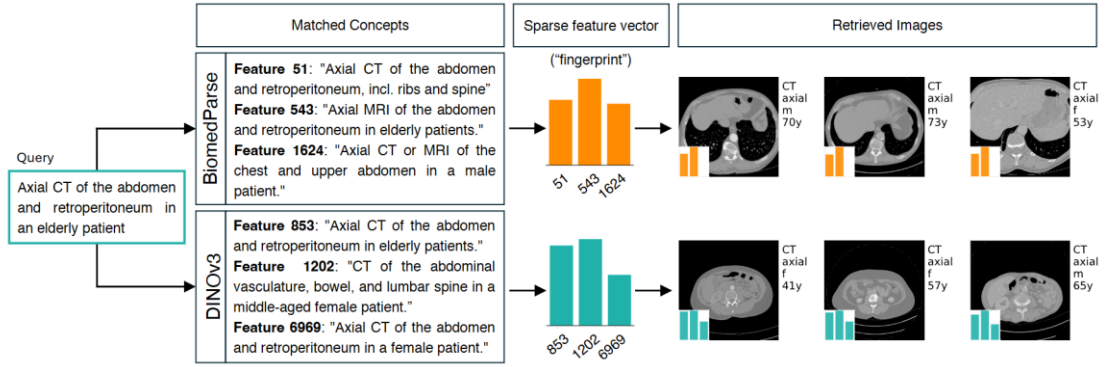


Table 2. Sparse fingerprint retrieval quality (mean cosine similarity to the reference image in the dense embedding space) as a function of fingerprint size k, averaged over $N = 1{,}000$ test images. *Dense*: full dense retrieval quality (upper bound).

Model	k=1	k=5	k=10	k=20	Dense
BiomedParse	0.93	0.95	0.96	0.97	0.98
DINOv3	0.75	0.83	0.85	0.86	0.89

Table 3. LLM-as-judge evaluation of automatically generated feature concepts for $N = 100$ features per model. An independent VLM ranks the true concept description among five candidates (1 true + 4 distractors) given the same images. Rank 1 = true concept fits best, Rank 5 = true concept fits worst.

Model	Mean rank	Rank 1	Rank 2	Rank 3	Rank 4	Rank 5
BiomedParse	1.48	70	17	9	3	1
DINOv3	1.26	83	11	3	3	0

Conclusion

- 저자들은 SAE가 의료 영상 모델의 임베딩을 해석 가능한 희소 특징으로 바꾸는 실용적인 층이 될 수 있다고 주장함.

- 의료 특화 BiomedParse보다 범용 DINOv3에서 더 단일하고 설명하기 쉬운 특징이 나왔다는 점이 특이하며, 저자들은 해석 가능성에 모델의 의료 분야 특화 여부보다 표현의 풍부함이 더 중요할 수 있다고 해석함.