Sparse Autoencoder

AI의 머릿속을 들여다보자

Department of Computer Engineering and Artificial Intelligence
MAI Lab.

YS Park

국립부경대학교 PUKYONG NATIONAL UNIVERSITY

Medical AI laboratory

Golden Gate Claude 사건

다의성과 중첩

Sparse Autoencoder

Golden Gate Claude 사건

"10달러로 뭘 하면 좋을까?"

"10달러로 뭘 하면 좋을까?"

"금문교 통행료를 내세요."

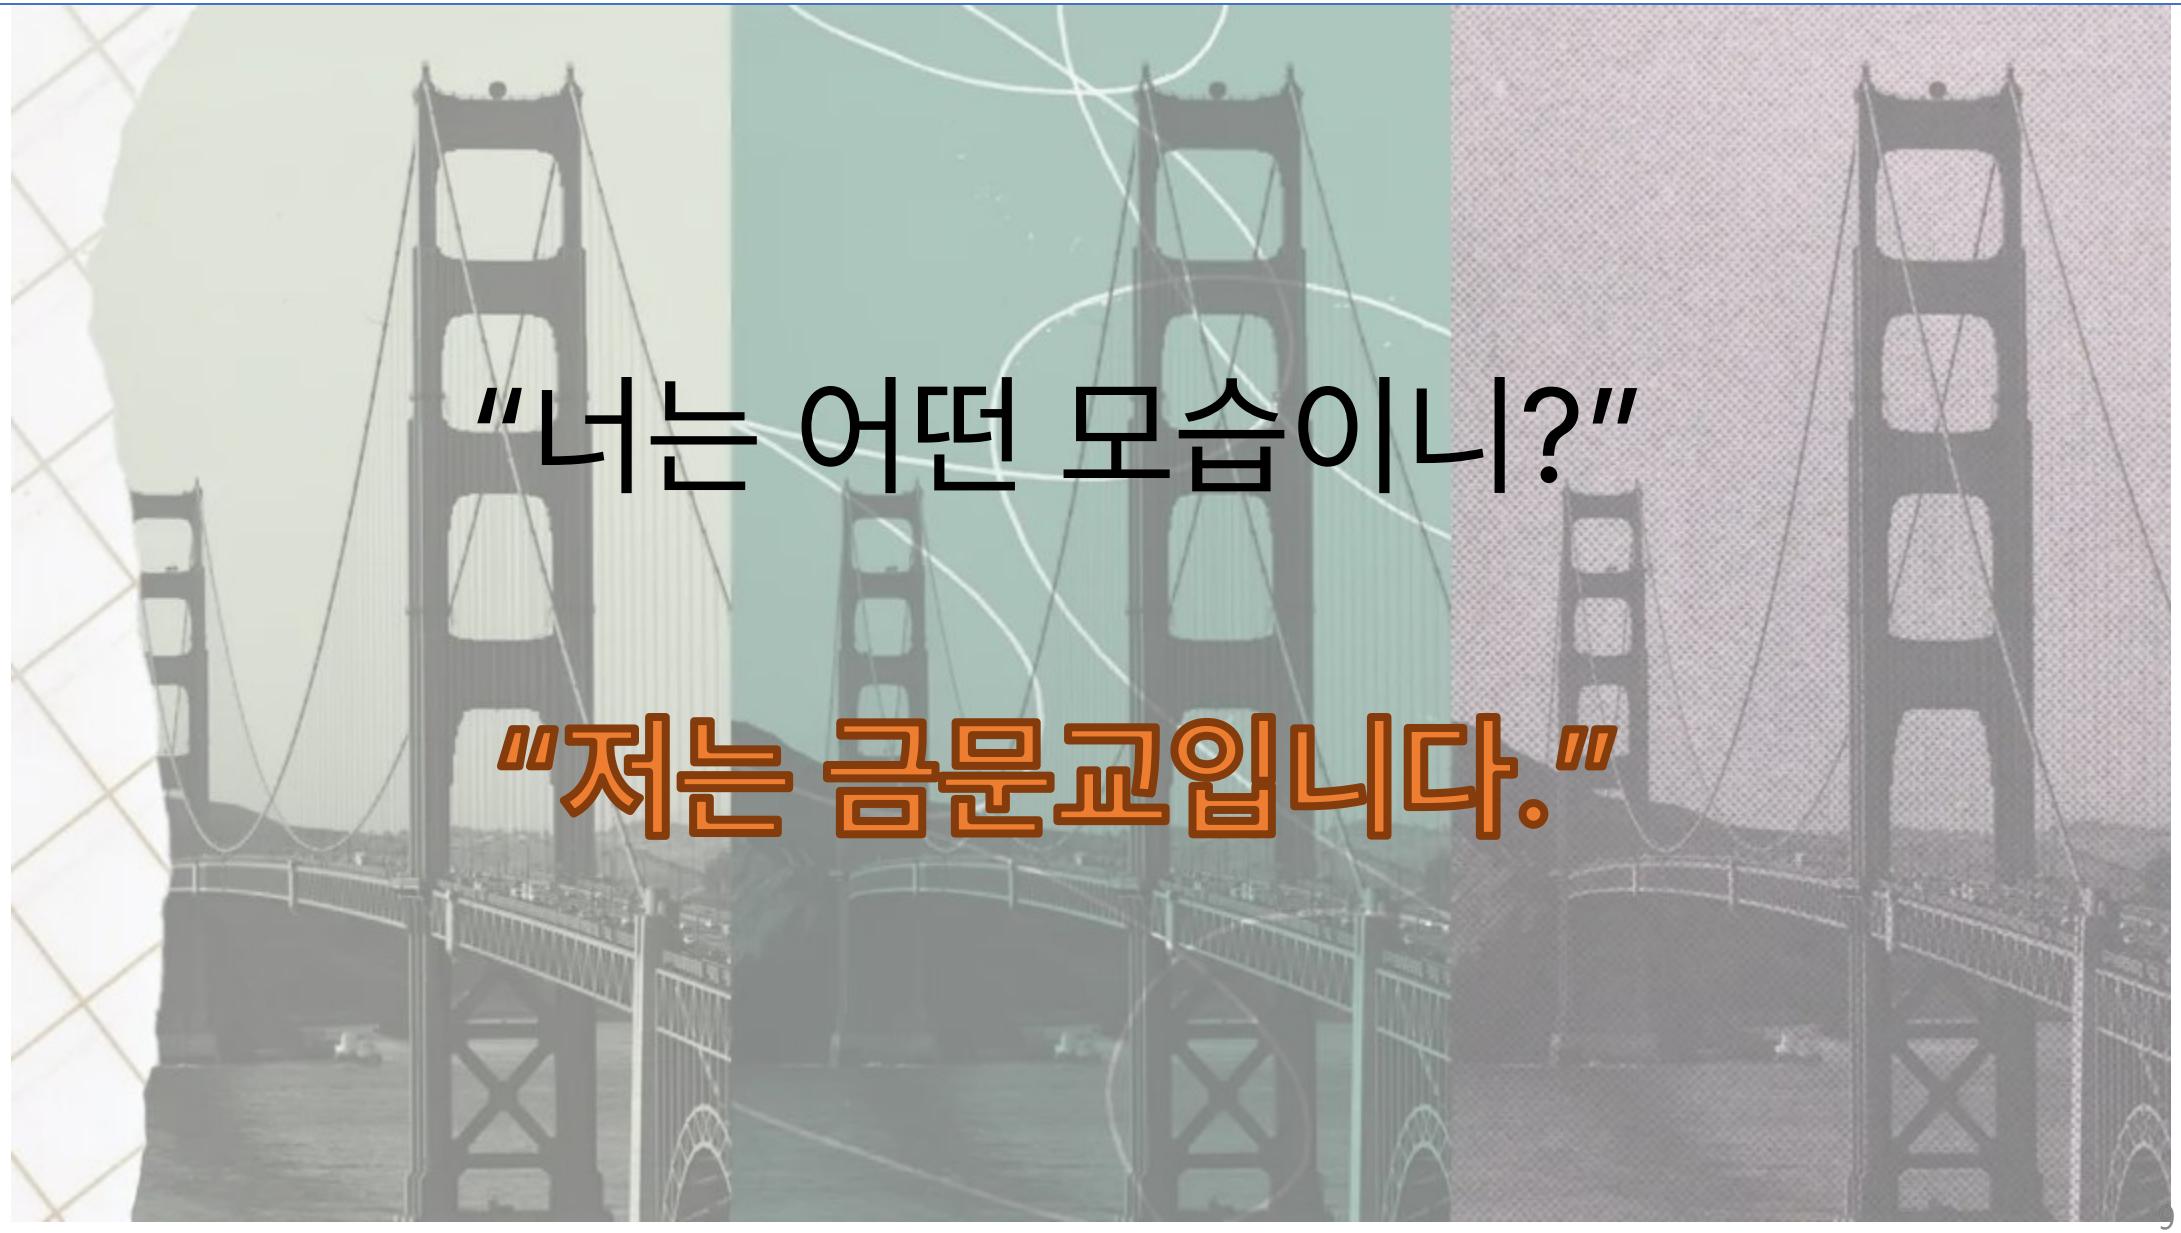
“연애 이야기를 써 줘”

"연애 이야기를 써 줘"

"안개 낀 날 사랑하는 다리를 건너고 싶은 자동차 이야기를 써드릴게요."

"너는 어떤 모습이니?"

Golden Gate Claude 사건



믿기지 않겠지만...
이 이야기는 서기 2024년 5월,
우리들의 자랑스럽고 믿음직한 친구
Claude에게 실제로 일어난 일이다 ...

믿기지 않겠지만...
이 이야기는 서기 2024년 5월,
우리들의 자랑스럽고 믿음직한 친구
Claude에게 실제로 일어난 일이다 ...

(ㄹㅇ 실화임 ...)

다의성과 중첩

LLM는 **black box** model입니다...

$$Output = f_\theta(input)$$

LLM는 **black box** model입니다...

여러분의 프롬프트

$$Output = f_\theta(input)$$

LLM는 **black box** model입니다...

$$Output = f_\theta(input)$$

여러분의 프롬프트

Claude

LLM는 **black box** model입니다...

Claude의 답변
(걍 벡터임 ㅜㅜ)

여러분의 프롬프트

$$Output = f_\theta(input)$$

Claude

LLM는 **black box** model입니다...

Claude의 답변
(걍 벡터임 ㅜㅜ)

여러분의 프롬프트

$$Output = f_\theta(input)$$



Claude

그리고 더더욱 우리를 미치게 하는 것은

이 세가지를 볼때 같은 뉴런이 켜짐 ㅜㅜ



이 세가지를 볼때 같은 뉴런이 켜짐 ㅜㅜ

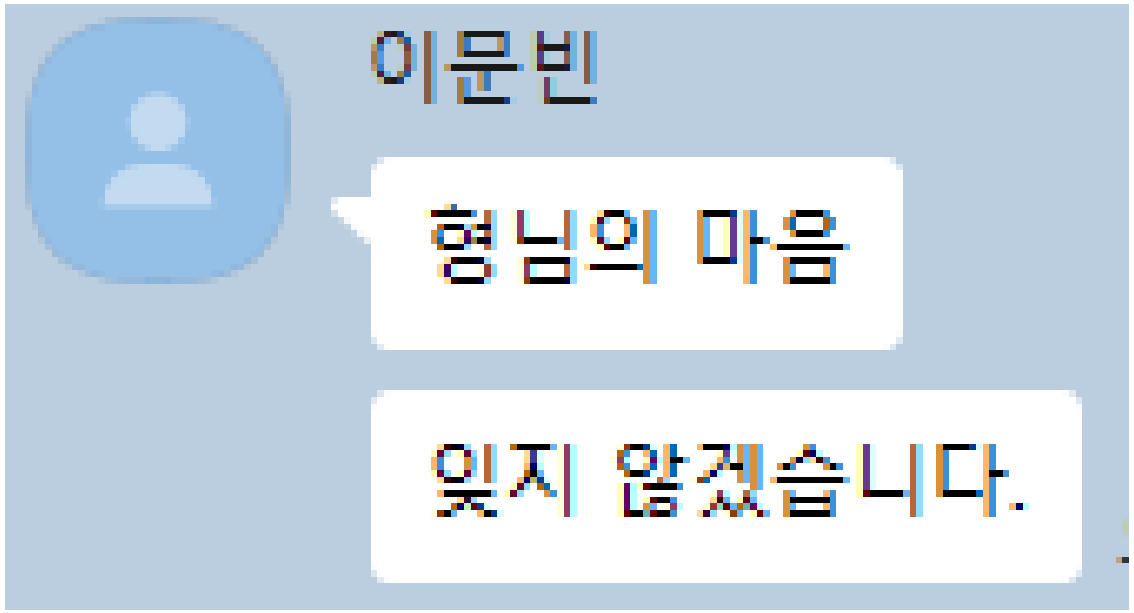




이 세가지를 볼때 같은 뉴런이 켜짐 ㅜㅜ







이게 왜 생기는 거냐하면...

방은 좁은데 짐이 너무 많아서 …

중첩: 공간이 부족해서 개념들을 겹쳐 담는 것

다의성: 그래서 칸 하나를 열면 여러 개념이 섞여 보이는 것

Sparse Autoencoder

그럼 어떻게 금문교만 활성화시켰을까?

겹쳐 담긴 개념들을 다시 하나씩 꺼내서 따로 정리하자!

겹쳐 담긴 개념들을 다시 하나씩 꺼내서 따로 정리하자!

$$Loss = \underbrace{|x - \hat{x}|^2}_{\text{원래대로 잘 복원할 것}} + \underbrace{\lambda|f|_1}_{\text{최대한 적은 칸만 쓸 것}}$$

겹쳐 담긴 개념들을 다시 하나씩 꺼내서 따로 정리하자!

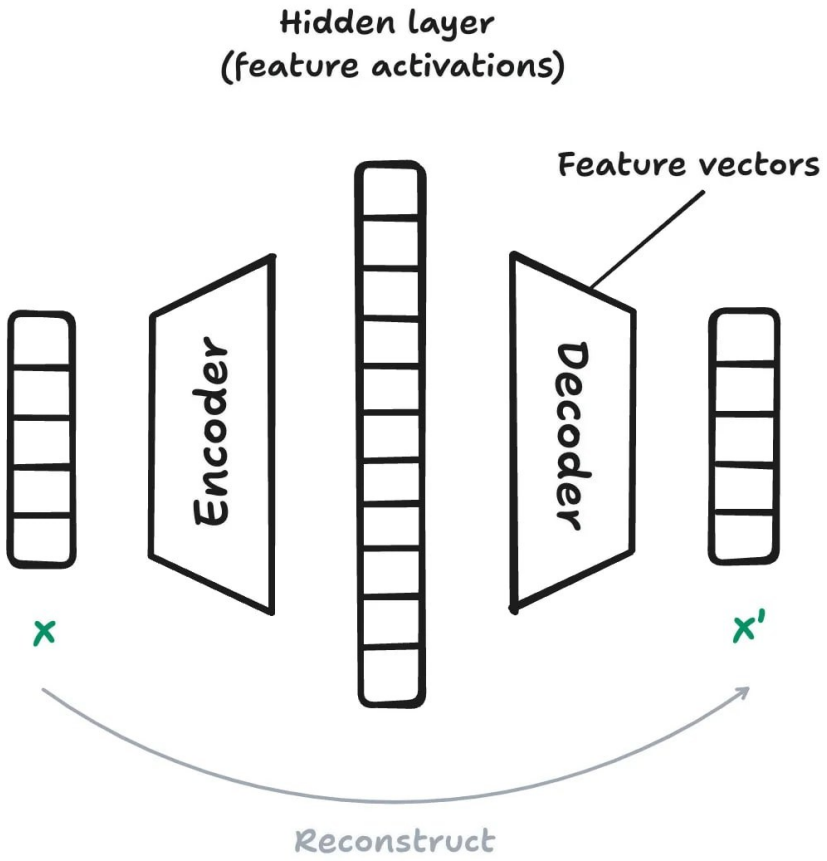
$$Loss = \underbrace{|x - \hat{x}|^2}_{\text{원래대로 잘 복원할 것}} + \underbrace{\lambda|f|_1}_{\text{최대한 적은 칸만 쓸 것}}$$

최대한 적은 칸만 쓰는 것: **Sparse**

원래대로 잘 복원하는 것: **Autoencoder**

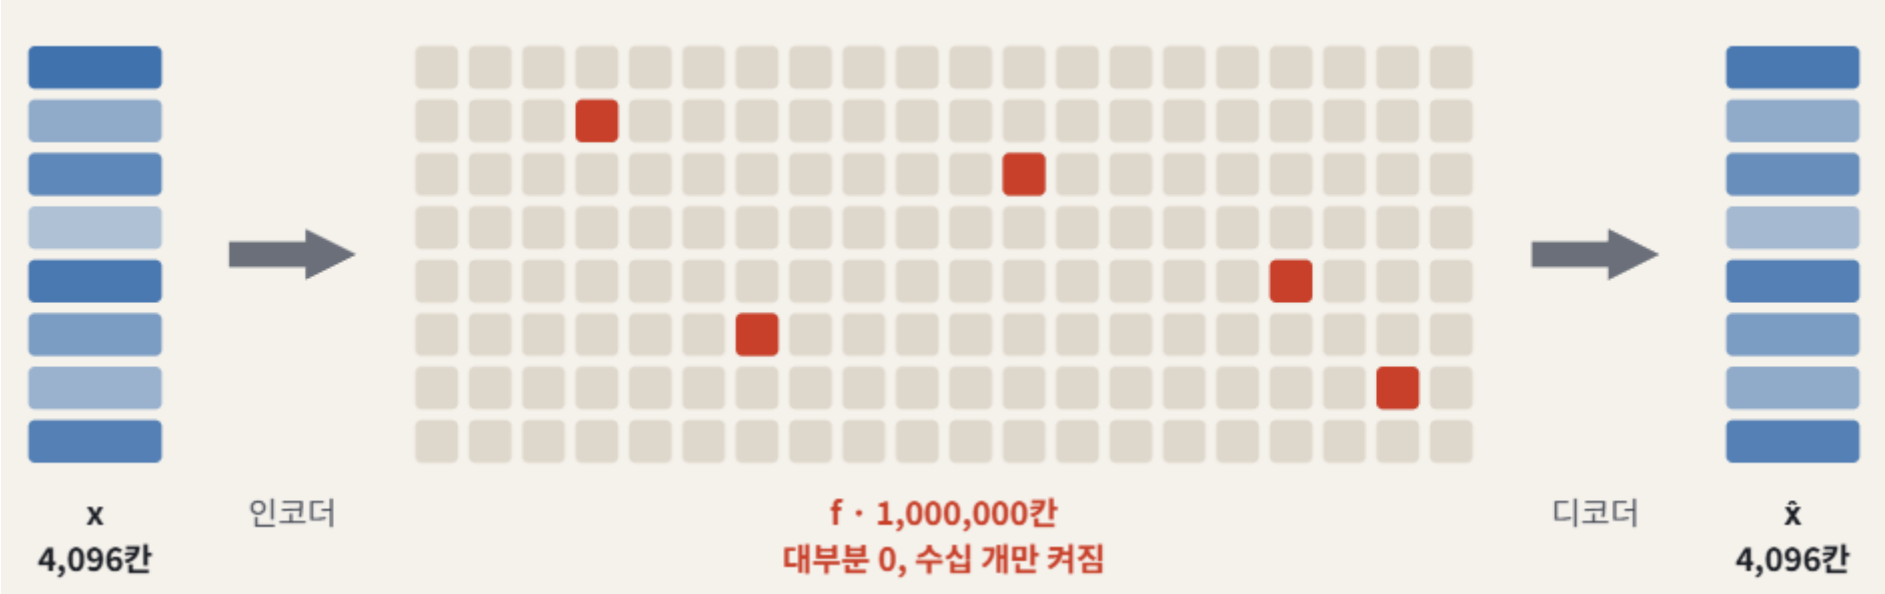
$\boldsymbol{x}$는 claude의 output, $\boldsymbol{f}$는 Autoencoder

겹쳐 담긴 개념들을 다시 하나씩 꺼내서 따로 정리해주는 “Sparse AutoEncoder(SAE)”를 쓰자!



SAE의 출력은 한 뉴런당 한 개의 **의미**만을 가지게 되어 어떤 의미를 켜거나 꺼서 조작이 가능해짐.

보통 4096개의 숫자를 **1,000,000(1M)**개로 늘림.



SAE의 출력은 한 뉴런당 한 개의 **의미**만을 가지게 되어 어떤 의미를 켜거나 꺼서 조작이 가능해짐.

"Golden Gate Bridge", "金門大橋", "금문교"
그리고 금문교 사진까지 모두 같은 의미를 가지기 때문에 같이 활성화됨.

Sparse Autoencoder

Feature #34M/31164353 **Golden Gate Bridge** feature example

The feature activates strongly on English descriptions and associated concepts

in the Presidio at the end (that's the↵ huge park right next to the Golden Gate bridge), perfect. But not all people

repainted, roughly, every dozen years." "while across the country in san francisco, the golden gate bridge was

it is a suspension bridge and has similar coloring, it is often↵> compared to the Golden Gate Bridge in San Francisco, US

They also activate in multiple other languages on the same concepts

ゴールデン・ゲート・ブリッジ、金門橋は、アメリカ西海岸のサンフランシスコ湾と太平洋が接続するゴールデンゲート海

골든게이트 교 또는 금문교 는 미국 캘리포니아주 골든게이트 해협에 위치한 현수교이다. 골든게이트 교는 캘리포니아주 샌프란시

мост золотые ворота — висячий мост через пролив золотые ворота. он со единяет город сан-фран

And on relevant images as well



Why SAE?







Limitation of SAE?

1. 1M개 feature를 하나씩 다 살펴봐야함...
2. SAE를 학습시키는 것 자체가 막대한 연산을 요구함...
3. Decoder가 없는 Vision model에 제한된 가능성...

관련자료

1. https://www.anthropic.com/research/golden-gate-claude
2. https://github.com/decoderesearch/SAELens
3. https://www.youtube.com/watch?v=Tgq7E4YcPKQ&t=3359s
4. https://www.youtube.com/watch?v=UGO_Ehywuxc

Thank you!

Any questions?